Aplicación de técnicas de aprendizaje supervisado para la identificación de fallas en motores de combustión interna

Juan David Gonzalez Rodriguez, Cristian Sanchez Garcia, Alejandro Guerra Urrego
Universidad de Antioquia
juand.gonzalez1@udea.edu.co
cristian.sanchez3@udea.edu.co
alejandro.guerrau@udea.edu.co

I. Descripción del problema

Los motores de combustión interna presentan diferentes condiciones de funcionamiento que pueden manifestarse en sus variables operativas, en el consumo de combustible y en la composición de los gases de escape. El análisis conjunto de estas mediciones permite estudiar el comportamiento del motor y reconocer patrones asociados con distintas condiciones de operación. Sin embargo, la relación entre estas variables puede ser compleja, debido a que una misma condición puede reflejarse en varias mediciones y una variable individual puede presentar comportamientos diferentes dependiendo del estado general del motor.

En este contexto, las técnicas de aprendizaje automático supervisado constituyen una alternativa para desarrollar modelos capaces de identificar patrones a partir de observaciones previamente etiquetadas. Mediante el entrenamiento con ejemplos conocidos, estos modelos pueden aprender relaciones entre las variables de entrada y las categorías de funcionamiento del motor, con el propósito de asignar una categoría a nuevas observaciones. De esta manera, es posible estudiar si la información contenida en las variables de operación y emisiones resulta suficiente para distinguir las condiciones representadas en los datos.

Este proyecto aborda un problema de clasificación multiclase utilizando el conjunto de datos *EngineFaultDB*. El objetivo consiste en evaluar la capacidad de diferentes modelos de aprendizaje automático supervisado para distinguir cuatro condiciones: funcionamiento normal, mezcla aire-combustible rica, mezcla aire-combustible pobre y bajo voltaje. Para ello, se emplean mediciones relacionadas con la admisión de aire, la posición del acelerador, el desempeño del motor, el consumo de combustible y las emisiones de gases.

A partir de este planteamiento, se formula la siguiente pregunta de investigación:

> *¿En qué medida los modelos de aprendizaje automático supervisado permiten identificar y diferenciar las condiciones de funcionamiento y fallas de un motor de combustión interna a partir de variables de operación y emisiones?*

El alcance del estudio se limita a la clasificación de las categorías presentes en el conjunto de datos. Por consiguiente, los resultados permitirán evaluar la capacidad de los modelos para predecir las etiquetas disponibles, pero no demostrarán por sí solos relaciones causales entre las variables ni garantizarán la generalización a motores, vehículos o condiciones de operación diferentes de los representados en los datos.

II. Descripción del conjunto de datos

II-A. Características generales

Para desarrollar el estudio se utiliza el conjunto de datos *EngineFaultDB*, proporcionado en el archivo `EngineFaultDB_Final.csv`. El archivo contiene 55 999 observaciones y 15 columnas, de las cuales 14 corresponden a variables predictoras numéricas y una corresponde a la variable objetivo `Fault`. Las variables predictoras describen distintos aspectos del funcionamiento del motor, el consumo de combustible y las emisiones producidas durante la combustión.

La combinación de estas variables permite representar el estado de funcionamiento del motor desde diferentes perspectivas. Por una parte, las mediciones relacionadas con la admisión y el acelerador aportan información sobre las condiciones de operación. Por otra, las variables de desempeño y consumo describen aspectos del comportamiento mecánico y energético. Finalmente, las mediciones de los gases de escape y la relación aire-combustible proporcionan información sobre el proceso de combustión.

Todas las variables predictoras se encuentran almacenadas en formato numérico de punto flotante. La variable objetivo utiliza valores enteros para codificar las cuatro categorías de clasificación. La inspección del archivo confirma que no existen valores faltantes en las columnas analizadas.

‘‘‘latex

II-B. Descripción de las variables predictoras

Las 14 variables predictoras pueden organizarse en cuatro grupos conceptuales: variables de admisión y control, variables de desempeño y velocidad, variables de consumo de combustible y variables relacionadas con las emisiones y la composición de la mezcla aire-combustible. Todas se

encuentran representadas mediante valores numéricos continuos en el conjunto de datos.

II-B1. Variables de admisión y control:

- `MAP`: corresponde a la presión absoluta del múltiple de admisión (*Manifold Absolute Pressure*). Esta variable caracteriza la presión del aire en el sistema de admisión y aporta información sobre las condiciones bajo las cuales el motor recibe aire para el proceso de combustión. Se codifica numéricamente como variable continua, con un rango observado de 0,453 a 4,547 kPa.
- `TPS`: corresponde a la señal del sensor de posición del acelerador (*Throttle Position Sensor*). Representa la posición del mecanismo de aceleración y permite caracterizar la demanda de operación asociada con la apertura del acelerador. Se representa mediante valores numéricos continuos, con un rango observado de 0,382 a 4,048 %.

II-B2. Variables de desempeño y velocidad:

- `Force`: representa una variable asociada con la fuerza desarrollada o registrada durante la operación del motor. Su interpretación física específica depende de la definición y las unidades utilizadas en la fuente de los datos. Se codifica como variable numérica continua, con valores entre 2,580 y 1537,118 N.
- `Power`: representa la potencia asociada con el funcionamiento del motor. Esta variable permite caracterizar su desempeño y puede aportar información para diferenciar condiciones de operación. Se representa numéricamente mediante valores continuos entre 0,465 y 33,946 kW.
- `RPM`: indica la velocidad de giro del motor, expresada habitualmente en revoluciones por minuto (*revolutions per minute*). Describe el régimen de operación y permite distinguir entre diferentes velocidades de funcionamiento. Se codifica como variable numérica continua, con valores entre 1066,452 y 5013,402 rpm.
- `Speed`: representa la velocidad de desplazamiento asociada con la observación. A diferencia de `RPM`, que describe la rotación del motor, esta variable caracteriza el movimiento del vehículo. Se representa mediante valores numéricos continuos entre 22,757 y 107,539 km/h.

II-B3. Variables de consumo de combustible:

- `Consumption L/H`: representa el consumo de combustible expresado en litros por hora. Esta medición describe la cantidad de combustible consumida por unidad de tiempo y permite estudiar el comportamiento energético del motor durante su funcionamiento. Se codifica numéricamente como variable continua, con valores entre 1,917 y 14,810 L/h.
- `Consumption L/100KM`: representa el consumo de combustible expresado en litros por cada 100 kilómetros. A diferencia de la variable anterior, relaciona el combustible consumido con la distancia recorrida y caracteriza la eficiencia del consumo durante el desplazamiento. Se representa mediante valores numéricos continuos entre 5,187 y 20,043 L/100 km.

Aunque ambas variables describen el consumo de combustible, no son equivalentes: una está relacionada con el tiempo y la otra con la distancia. Su inclusión conjunta puede proporcionar información complementaria, aunque también será pertinente estudiar la correlación entre ellas durante el análisis exploratorio.

II-B4. Variables de emisiones y composición de la mezcla:

- `CO`: representa la concentración de monóxido de carbono en los gases de escape. Este gas se produce, entre otros mecanismos, durante la combustión incompleta del combustible. Su medición aporta información sobre las características del proceso de combustión. Se codifica como variable numérica continua, con valores entre 0,421 y 10,132 %.
- `HC`: representa la concentración de hidrocarburos en los gases de escape. Estas emisiones pueden estar asociadas con combustible que no se ha oxidado completamente durante la combustión. Su valor permite caracterizar otro aspecto de las emisiones generadas por el motor. Se representa numéricamente mediante valores continuos entre 1,787 y 975,657 ppm.
- `CO2`: representa la concentración de dióxido de carbono en los gases de escape. Su medición está relacionada con la oxidación del carbono presente en el combustible y puede aportar información complementaria sobre el proceso de combustión. Se codifica como variable numérica continua, con valores entre 8,649 y 15,129 %.
- `O2`: representa la concentración de oxígeno en los gases de escape. Esta variable permite estudiar la presencia de oxígeno remanente después del proceso de combustión y, en conjunto con otras mediciones, aporta información sobre las condiciones de la mezcla aire-combustible. Se representa mediante valores numéricos continuos entre 0,203 y 1,151 %.
- `Lambda`: representa la relación entre la proporción aire-combustible real y la proporción estequiométrica de referencia. Bajo esta interpretación habitual, valores de lambda inferiores a uno corresponden a mezclas ricas, valores superiores a uno a mezclas pobres y un valor cercano a uno a una mezcla próxima a la condición estequiométrica. Se codifica como variable numérica continua y adimensional, con valores entre 0,695 y 1,149.
- `AFR`: corresponde a la relación aire-combustible (*Air-Fuel Ratio*), que expresa la cantidad de aire en relación con la cantidad de combustible utilizada en la mezcla. Esta variable describe directamente una característica central del proceso de combustión. Su interpretación cuantitativa depende de las unidades y de la convención empleadas en los datos. Se representa mediante valores numéricos continuos entre 10,210 y 16,893.

Las variables `Lambda`, `AFR`, `O2` y las concentraciones de gases pueden contener información relacionada entre sí, debido a que describen distintos aspectos de la combustión y sus productos. Por esta razón, resulta pertinente analizar sus

Cuadro I
DISTRIBUCIÓN DE LA VARIABLE OBJETIVO FAULT

Código	Categoría	Observaciones	Porcentaje
0	Funcionamiento normal	16 000	28.57 %
1	Mezcla rica	10 998	19.64 %
2	Mezcla pobre	15 000	26.79 %
3	Bajo voltaje	14 001	25.00 %
Total		**55 999**	**100.00 %**

relaciones estadísticas antes del entrenamiento de los modelos. No obstante, la posible correlación entre variables no implica que sean completamente redundantes ni que deban eliminarse sin una evaluación previa. “‘

II-C. Variable objetivo y distribución de las clases

La variable `Fault` constituye la variable objetivo del problema de clasificación. Sus valores representan cuatro categorías de funcionamiento, descritas en la Tabla I. Cada observación contiene una única etiqueta, por lo que el problema se formula como una tarea de clasificación multiclase.

La clase de funcionamiento normal representa aproximadamente el 28.57 % de las observaciones, mientras que las categorías de mezcla pobre y bajo voltaje representan el 26.79 % y el 25.00 %, respectivamente. La categoría de mezcla rica presenta la menor frecuencia, con el 19.64 % del conjunto de datos.

Aunque las frecuencias no son idénticas, las cuatro clases tienen una representación considerable dentro del conjunto de datos. Por ello, la evaluación no debe limitarse a la exactitud global (*accuracy*), ya que esta métrica por sí sola no permite determinar si el modelo identifica adecuadamente cada condición. Se considerarán también métricas como la precisión, la exhaustividad (*recall*), la medida F1 y la matriz de confusión para analizar los aciertos y errores asociados con cada categoría.

II-D. Formulación del problema de aprendizaje

Formalmente, el conjunto de datos puede representarse como

$$\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^{N}, \tag{1}$$

donde $N = 55\,999$ es el número de observaciones, $\mathbf{x}_i \in R^{14}$ es el vector de variables predictoras correspondiente a la observación i, y $y_i \in \{0, 1, 2, 3\}$ es su etiqueta de clase.

El propósito del aprendizaje consiste en estimar una función de clasificación

$$f : R^{14} \to \{0, 1, 2, 3\}, \tag{2}$$

capaz de asignar una categoría a nuevas observaciones a partir de sus variables predictoras. Para ello, los modelos se entrenarán utilizando las observaciones disponibles y posteriormente se evaluará su desempeño sobre datos no utilizados durante el entrenamiento.

Durante este proceso, la variable `Fault` se utilizará exclusivamente como etiqueta objetivo y no como variable predictora, con el fin de evitar que el modelo tenga acceso directo a la respuesta que debe aprender a estimar. “‘

“‘latex

III. ESTADO DEL ARTE

El diagnóstico de fallas en motores de combustión interna se ha abordado como un problema de clasificación supervisada. Sin embargo, los estudios difieren en datos, variables y protocolos de evaluación, por lo que sus métricas no son directamente comparables. A continuación se resumen cuatro trabajos relevantes.

Vergara et al. [1] presentan EngineFaultDB y una línea base de clasificación multiclase (cuatro categorías). Evalúan regresión logística, árbol de decisión, bosque aleatorio, SVM, k-NN, Naive Bayes y una red neuronal con una capa oculta de nueve neuronas, usando escalado Min-Max, partición 80/20 y configuraciones estándar sin ajuste de hiperparámetros. Reportan exactitud, precisión, exhaustividad y F1. Árbol y bosque alcanzan desempeño perfecto en entrenamiento pero cercano a 0.75 en prueba, lo que evidencia sobreajuste; k-NN y la red neuronal también rondan 0.75, y los errores se concentran entre las fallas 2 y 3.

Nguyen et al. [2] usan el mismo conjunto de datos, pero excluyen RPM y AFR. Comparan bosque aleatorio, MLP y un ensamble por votación mayoritaria, aplicando la estrategia uno-contra-el-resto (*One-vs-Rest*) para el problema multiclase, con búsqueda en cuadrícula y validación cruzada de cinco particiones. Emplean las mismas métricas. El MLP obtiene la mayor exactitud y el bosque aleatorio el mejor F1, mientras que el ensamble no supera de forma significativa a los modelos individuales; persiste la confusión entre las fallas 2 y 3.

Srinivaas et al. [3] diagnostican el corte de inyección en un motor de cuatro cilindros (cinco clases) a partir de vibraciones, bajo cargas de 0, 15 y 30 %. Comparan 16 clasificadores clásicos y modelos profundos (DNN, 1D-CNN, Transformer) con PCA, MRMR, Chi2, ReliefF, ANOVA y Kruskal–Wallis, mediante validación cruzada de 10 particiones. Usan exactitud, F1, ROC-AUC y un costo total, definido como la suma de penalizaciones de una matriz de costos de errores, $\sum_{i,j} n_{ij} c_{ij}$. El discriminante lineal y la SVM lineal resultan los más estables, PCA perjudica al árbol fino, y el Transformer alcanza 99.02 % de exactitud con 15 % de carga.

Cajías et al. [4] estudian el diagnóstico predictivo en vehículos a partir de datos de flota (temperatura, presión de aceite, vibración y emisiones). Seleccionan variables con bosque aleatorio y PCA, entrenan árboles, SVM y redes neuronales con partición estratificada 70/30, y evalúan exactitud, sensibilidad, especificidad ($\mathrm{TN}/(\mathrm{TN}+\mathrm{FP})$), F1 y curvas ROC. La red neuronal supera a SVM y árboles; su matriz de confusión reportada (780 VN, 645 VP, 45 FP, 30 FN) equivale a una exactitud aproximada de 95 %.

Síntesis. Los resultados dependen del conjunto de datos, las clases y la validación, por lo que las cifras de los trabajos con otras señales no son una referencia directa para EngineFaultDB. Los estudios sobre este conjunto usan particiones fijas o ajuste limitado, y reportan confusión sistemática entre las fallas 2 y 3.

Este proyecto compara modelos bajo un protocolo común con ajuste de hiperparámetros, intervalos de confianza y análisis por clase, y estudia el efecto de PCA y UMAP. “‘

REFERENCIAS

[1] M. Vergara, L. Ramos, N. D. Rivera-Campoverde, and F. Rivas-Echeverría, “EngineFaultDB: A novel dataset for automotive engine fault classification and baseline results,” *IEEE Access*, vol. 11, pp. 126155–126171, 2023, doi: 10.1109/ACCESS.2023.3331316.

[2] V. T. Nguyen, T. P. Nguyen, and L. V. Dat, “AI-based automotive engine diagnostics: Exploring the EngineFaultDB dataset for fault detection,” *HaUI Journal of Science and Technology*, vol. 61, no. 7E, Jul. 2025, doi: 10.57001/huih5804.2025.248.

[3] A. Srinivaas, N. R. Sakthivel, and B. B. Nair, “Machine learning approaches for fault detection in internal combustion engines: A review and experimental investigation,” *Informatics*, vol. 12, no. 1, Art. no. 25, Feb. 2025, doi: 10.3390/informatics12010025.

[4] P. R. Cajías-Arías, J. C. Ortiz-Reyes, C. S. Ulcuango-Moreno, and R. R. Alay-Romero, “Integración de inteligencia artificial para el diagnóstico predictivo de fallas mecánicas en vehículos de combustión interna: Enfoque integral,” *Polo del Conocimiento*, vol. 10, no. 5, pp. 2271–2289, May 2025, doi: 10.23857/pc.v10i5.9570.