Aplicación de técnicas de aprendizaje supervisado para la identificación de fallas en motores de combustión interna

Juan David Gonzalez Rodriguez, Cristian Sanchez Garcia, Alejandro Guerra Urrego
Universidad de Antioquia
juand.gonzalez1@udea.edu.co
cristian.sanchez3@udea.edu.co
alejandro.guerrau@udea.edu.co

I. Descripción del problema

Los motores de combustión interna presentan diferentes condiciones de funcionamiento que pueden manifestarse en sus variables operativas, en el consumo de combustible y en la composición de los gases de escape. El análisis conjunto de estas mediciones permite estudiar el comportamiento del motor y reconocer patrones asociados con distintas condiciones de operación. Sin embargo, la relación entre estas variables puede ser compleja, debido a que una misma condición puede reflejarse en varias mediciones y una variable individual puede presentar comportamientos diferentes dependiendo del estado general del motor.

En este contexto, las técnicas de aprendizaje automático supervisado constituyen una alternativa para desarrollar modelos capaces de identificar patrones a partir de observaciones previamente etiquetadas. Mediante el entrenamiento con ejemplos conocidos, estos modelos pueden aprender relaciones entre las variables de entrada y las categorías de funcionamiento del motor, con el propósito de asignar una categoría a nuevas observaciones. De esta manera, es posible estudiar si la información contenida en las variables de operación y emisiones resulta suficiente para distinguir las condiciones representadas en los datos.

Este proyecto aborda un problema de clasificación multiclase utilizando el conjunto de datos *EngineFaultDB*. El objetivo consiste en evaluar la capacidad de diferentes modelos de aprendizaje automático supervisado para distinguir cuatro condiciones: funcionamiento normal, mezcla aire-combustible rica, mezcla aire-combustible pobre y bajo voltaje. Para ello, se emplean mediciones relacionadas con la admisión de aire, la posición del acelerador, el desempeño del motor, el consumo de combustible y las emisiones de gases.

A partir de este planteamiento, se formula la siguiente pregunta de investigación:

> *¿En qué medida los modelos de aprendizaje automático supervisado permiten identificar y diferenciar las condiciones de funcionamiento y fallas de un motor de combustión interna a partir de variables de operación y emisiones?*

El alcance del estudio se limita a la clasificación de las categorías presentes en el conjunto de datos. Por consiguiente, los resultados permitirán evaluar la capacidad de los modelos para predecir las etiquetas disponibles, pero no demostrarán por sí solos relaciones causales entre las variables ni garantizarán la generalización a motores, vehículos o condiciones de operación diferentes de los representados en los datos.

II. Descripción del conjunto de datos

II-A. Características generales

Para desarrollar el estudio se utiliza el conjunto de datos *EngineFaultDB*, proporcionado en el archivo `EngineFaultDB_Final.csv`. El archivo contiene 55 999 observaciones y 15 columnas, de las cuales 14 corresponden a variables predictoras numéricas y una corresponde a la variable objetivo `Fault`. Las variables predictoras describen distintos aspectos del funcionamiento del motor, el consumo de combustible y las emisiones producidas durante la combustión.

La combinación de estas variables permite representar el estado de funcionamiento del motor desde diferentes perspectivas. Por una parte, las mediciones relacionadas con la admisión y el acelerador aportan información sobre las condiciones de operación. Por otra, las variables de desempeño y consumo describen aspectos del comportamiento mecánico y energético. Finalmente, las mediciones de los gases de escape y la relación aire-combustible proporcionan información sobre el proceso de combustión.

Todas las variables predictoras se encuentran almacenadas en formato numérico de punto flotante. La variable objetivo utiliza valores enteros para codificar las cuatro categorías de clasificación. La inspección del archivo confirma que no existen valores faltantes en las columnas analizadas.

‘‘‘latex

II-B. Descripción de las variables predictoras

Las 14 variables predictoras pueden organizarse en cuatro grupos conceptuales: variables de admisión y control, variables de desempeño y velocidad, variables de consumo de combustible y variables relacionadas con las emisiones y la composición de la mezcla aire-combustible. Todas se

encuentran representadas mediante valores numéricos continuos en el conjunto de datos.

II-B1. Variables de admisión y control:

- `MAP`: corresponde a la presión absoluta del múltiple de admisión (*Manifold Absolute Pressure*). Esta variable caracteriza la presión del aire en el sistema de admisión y aporta información sobre las condiciones bajo las cuales el motor recibe aire para el proceso de combustión. Se codifica numéricamente como variable continua, con un rango observado de 0,453 a 4,547 kPa.
- `TPS`: corresponde a la señal del sensor de posición del acelerador (*Throttle Position Sensor*). Representa la posición del mecanismo de aceleración y permite caracterizar la demanda de operación asociada con la apertura del acelerador. Se representa mediante valores numéricos continuos, con un rango observado de 0,382 a 4,048 %.

II-B2. Variables de desempeño y velocidad:

- `Force`: representa una variable asociada con la fuerza desarrollada o registrada durante la operación del motor. Su interpretación física específica depende de la definición y las unidades utilizadas en la fuente de los datos. Se codifica como variable numérica continua, con valores entre 2,580 y 1537,118 N.
- `Power`: representa la potencia asociada con el funcionamiento del motor. Esta variable permite caracterizar su desempeño y puede aportar información para diferenciar condiciones de operación. Se representa numéricamente mediante valores continuos entre 0,465 y 33,946 kW.
- `RPM`: indica la velocidad de giro del motor, expresada habitualmente en revoluciones por minuto (*revolutions per minute*). Describe el régimen de operación y permite distinguir entre diferentes velocidades de funcionamiento. Se codifica como variable numérica continua, con valores entre 1066,452 y 5013,402 rpm.
- `Speed`: representa la velocidad de desplazamiento asociada con la observación. A diferencia de `RPM`, que describe la rotación del motor, esta variable caracteriza el movimiento del vehículo. Se representa mediante valores numéricos continuos entre 22,757 y 107,539 km/h.

II-B3. Variables de consumo de combustible:

- `Consumption L/H`: representa el consumo de combustible expresado en litros por hora. Esta medición describe la cantidad de combustible consumida por unidad de tiempo y permite estudiar el comportamiento energético del motor durante su funcionamiento. Se codifica numéricamente como variable continua, con valores entre 1,917 y 14,810 L/h.
- `Consumption L/100KM`: representa el consumo de combustible expresado en litros por cada 100 kilómetros. A diferencia de la variable anterior, relaciona el combustible consumido con la distancia recorrida y caracteriza la eficiencia del consumo durante el desplazamiento. Se representa mediante valores numéricos continuos entre 5,187 y 20,043 L/100 km.

Aunque ambas variables describen el consumo de combustible, no son equivalentes: una está relacionada con el tiempo y la otra con la distancia. Su inclusión conjunta puede proporcionar información complementaria, aunque también será pertinente estudiar la correlación entre ellas durante el análisis exploratorio.

II-B4. Variables de emisiones y composición de la mezcla:

- `CO`: representa la concentración de monóxido de carbono en los gases de escape. Este gas se produce, entre otros mecanismos, durante la combustión incompleta del combustible. Su medición aporta información sobre las características del proceso de combustión. Se codifica como variable numérica continua, con valores entre 0,421 y 10,132 %.
- `HC`: representa la concentración de hidrocarburos en los gases de escape. Estas emisiones pueden estar asociadas con combustible que no se ha oxidado completamente durante la combustión. Su valor permite caracterizar otro aspecto de las emisiones generadas por el motor. Se representa numéricamente mediante valores continuos entre 1,787 y 975,657 ppm.
- `CO2`: representa la concentración de dióxido de carbono en los gases de escape. Su medición está relacionada con la oxidación del carbono presente en el combustible y puede aportar información complementaria sobre el proceso de combustión. Se codifica como variable numérica continua, con valores entre 8,649 y 15,129 %.
- `O2`: representa la concentración de oxígeno en los gases de escape. Esta variable permite estudiar la presencia de oxígeno remanente después del proceso de combustión y, en conjunto con otras mediciones, aporta información sobre las condiciones de la mezcla aire-combustible. Se representa mediante valores numéricos continuos entre 0,203 y 1,151 %.
- `Lambda`: representa la relación entre la proporción aire-combustible real y la proporción estequiométrica de referencia. Bajo esta interpretación habitual, valores de lambda inferiores a uno corresponden a mezclas ricas, valores superiores a uno a mezclas pobres y un valor cercano a uno a una mezcla próxima a la condición estequiométrica. Se codifica como variable numérica continua y adimensional, con valores entre 0,695 y 1,149.
- `AFR`: corresponde a la relación aire-combustible (*Air-Fuel Ratio*), que expresa la cantidad de aire en relación con la cantidad de combustible utilizada en la mezcla. Esta variable describe directamente una característica central del proceso de combustión. Su interpretación cuantitativa depende de las unidades y de la convención empleadas en los datos. Se representa mediante valores numéricos continuos entre 10,210 y 16,893.

Las variables `Lambda`, `AFR`, `O2` y las concentraciones de gases pueden contener información relacionada entre sí, debido a que describen distintos aspectos de la combustión y sus productos. Por esta razón, resulta pertinente analizar sus

Cuadro I
DISTRIBUCIÓN DE LA VARIABLE OBJETIVO FAULT

Código	Categoría	Observaciones	Porcentaje
0	Funcionamiento normal	16 000	28.57 %
1	Mezcla rica	10 998	19.64 %
2	Mezcla pobre	15 000	26.79 %
3	Bajo voltaje	14 001	25.00 %
Total		**55 999**	**100.00 %**

relaciones estadísticas antes del entrenamiento de los modelos. No obstante, la posible correlación entre variables no implica que sean completamente redundantes ni que deban eliminarse sin una evaluación previa. “‘

II-C. Variable objetivo y distribución de las clases

La variable `Fault` constituye la variable objetivo del problema de clasificación. Sus valores representan cuatro categorías de funcionamiento, descritas en la Tabla I. Cada observación contiene una única etiqueta, por lo que el problema se formula como una tarea de clasificación multiclase.

La clase de funcionamiento normal representa aproximadamente el 28.57 % de las observaciones, mientras que las categorías de mezcla pobre y bajo voltaje representan el 26.79 % y el 25.00 %, respectivamente. La categoría de mezcla rica presenta la menor frecuencia, con el 19.64 % del conjunto de datos.

Aunque las frecuencias no son idénticas, las cuatro clases tienen una representación considerable dentro del conjunto de datos. Por ello, la evaluación no debe limitarse a la exactitud global (*accuracy*), ya que esta métrica por sí sola no permite determinar si el modelo identifica adecuadamente cada condición. Se considerarán también métricas como la precisión, la exhaustividad (*recall*), la medida F1 y la matriz de confusión para analizar los aciertos y errores asociados con cada categoría.

II-D. Formulación del problema de aprendizaje

Formalmente, el conjunto de datos puede representarse como

$$\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^{N}, \tag{1}$$

donde $N = 55\,999$ es el número de observaciones, $\mathbf{x}_i \in R^{14}$ es el vector de variables predictoras correspondiente a la observación i, y $y_i \in \{0, 1, 2, 3\}$ es su etiqueta de clase.

El propósito del aprendizaje consiste en estimar una función de clasificación

$$f : R^{14} \to \{0, 1, 2, 3\}, \tag{2}$$

capaz de asignar una categoría a nuevas observaciones a partir de sus variables predictoras. Para ello, los modelos se entrenarán utilizando las observaciones disponibles y posteriormente se evaluará su desempeño sobre datos no utilizados durante el entrenamiento.

Durante este proceso, la variable `Fault` se utilizará exclusivamente como etiqueta objetivo y no como variable predictora, con el fin de evitar que el modelo tenga acceso directo a la respuesta que debe aprender a estimar. “‘

“‘latex

III. ESTADO DEL ARTE

El diagnóstico de fallas en motores de combustión interna mediante técnicas de aprendizaje automático se ha estudiado como un problema de clasificación supervisada, en el que las variables de funcionamiento del motor se utilizan para identificar condiciones normales o estados de falla. Sin embargo, los estudios disponibles presentan diferencias en los conjuntos de datos, las variables de entrada, las arquitecturas de los modelos y los protocolos de evaluación. Por esta razón, sus resultados deben interpretarse considerando las características de cada experimento, en lugar de compararse únicamente a partir de una métrica global.

En este contexto, se revisan investigaciones relacionadas con la clasificación de fallas a partir de datos de funcionamiento de motores, con especial atención a los trabajos que utilizan EngineFaultDB. También se consideran estudios complementarios que abordan el diagnóstico mediante otras fuentes de información y técnicas de representación de los datos.

III-A. Clasificación de fallas con EngineFaultDB

Vergara et al. [**?**] estudian la clasificación de condiciones de funcionamiento de motores de combustión interna mediante EngineFaultDB. Este conjunto de datos contempla cuatro categorías: funcionamiento normal, mezcla aire-combustible rica, mezcla aire-combustible pobre y bajo voltaje. Los autores evalúan diferentes algoritmos de aprendizaje automático, entre ellos regresión logística, árbol de decisión, bosque aleatorio, máquina de soporte vectorial, k vecinos más cercanos, Naive Bayes y una red neuronal de propagación hacia adelante con una capa oculta de nueve neuronas.

Como parte del procesamiento, los autores aplican escalado Min-Max y emplean una partición de los datos para entrenamiento y prueba con una proporción de 80 % y 20 %, respectivamente. El desempeño se analiza mediante métricas como exactitud, precisión, exhaustividad y puntuación F1. Los resultados reportados muestran diferencias entre los clasificadores: algunos modelos basados en árboles obtienen un desempeño muy elevado durante el entrenamiento, pero su rendimiento disminuye en el conjunto de prueba, lo que evidencia la importancia de examinar la capacidad de generalización y no solamente el ajuste a los datos de entrenamiento. Asimismo, se reportan confusiones entre algunas categorías de falla, lo que indica que el desempeño global no necesariamente refleja una identificación uniforme de todas las clases.

Este trabajo constituye un punto de referencia para el presente proyecto, dado que utiliza el mismo conjunto de datos y considera las cuatro categorías de interés. No obstante, sus resultados corresponden a la configuración experimental y a los modelos evaluados en dicho estudio. Por ello, cualquier comparación con nuevos experimentos debe considerar tanto las variables empleadas como el procedimiento de partición, el preprocesamiento y los criterios de evaluación.

Por su parte, Nguyen et al. [**?**] también estudian la clasificación de fallas utilizando EngineFaultDB, pero consideran una configuración de entrada diferente al excluir las variables RPM y AFR. Su metodología incluye modelos como bosque aleatorio y perceptrón multicapa (*Multilayer Perceptron*, MLP), además de un enfoque de ensamble basado en votación mayoritaria. Para seleccionar la configuración de los modelos, los autores utilizan búsqueda en cuadrícula (*grid search*) y validación cruzada de cinco particiones.

La evaluación considera métricas de clasificación como exactitud, precisión, exhaustividad y puntuación F1. Los resultados permiten analizar el comportamiento individual de los clasificadores y del ensamble bajo la configuración propuesta. Sin embargo, la combinación de modelos no implica necesariamente una mejora frente a los clasificadores individuales. Además, se observan dificultades para distinguir algunas categorías de falla, lo cual refuerza la necesidad de analizar la matriz de confusión y el desempeño por clase.

La diferencia en las variables de entrada es relevante para interpretar estos resultados. Aunque ambos estudios utilizan EngineFaultDB, la exclusión de RPM y AFR modifica la información disponible para los clasificadores y, por tanto, puede afectar su desempeño. Asimismo, el uso de búsqueda de hiperparámetros y validación cruzada en Nguyen et al. representa una diferencia metodológica respecto de una evaluación basada únicamente en una partición fija. En consecuencia, estos trabajos ofrecen referencias complementarias, pero sus resultados no deben considerarse directamente equivalentes sin controlar las diferencias experimentales.

III-B. Diagnóstico de fallas mediante otras fuentes de datos

Además de los estudios que utilizan EngineFaultDB, otras investigaciones abordan el diagnóstico de motores a partir de señales y condiciones de funcionamiento diferentes. Srinivaas et al. [**?**] analizan la detección de fallas asociadas con la interrupción de la inyección de combustible en un motor de cuatro cilindros. El problema se formula como una clasificación de cinco categorías y se estudia bajo distintas condiciones de carga del motor, utilizando señales de vibración como fuente de información.

Los autores comparan clasificadores convencionales y modelos de aprendizaje profundo, entre ellos redes neuronales profundas, redes convolucionales unidimensionales y arquitecturas basadas en Transformer. También examinan métodos de selección y transformación de características, como el análisis de componentes principales (PCA), junto con otras técnicas de selección de variables. La evaluación incluye validación cruzada y métricas como exactitud, puntuación F1 y área bajo la curva ROC.

Los resultados muestran que el desempeño depende tanto del clasificador como de la representación de los datos y de las condiciones de carga. Algunas configuraciones basadas en arquitecturas profundas alcanzan resultados elevados bajo condiciones específicas; sin embargo, estos valores corresponden al problema, las señales y las condiciones experimentales de ese estudio. Por tanto, no constituyen una referencia directamente comparable con la clasificación de las cuatro categorías de EngineFaultDB, ya que cambian tanto la definición de las fallas como la fuente de información utilizada.

Este trabajo resulta relevante para el presente proyecto porque muestra que la representación de los datos y la selección de características pueden influir en el rendimiento de los modelos. También evidencia que una técnica de reducción de dimensionalidad no necesariamente beneficia a todos los clasificadores por igual. En consecuencia, su efecto debe analizarse de forma experimental para cada combinación de datos y modelo.

Cajías et al. [**?**] estudian la integración de técnicas de inteligencia artificial para el diagnóstico predictivo de fallas mecánicas en vehículos de combustión interna. Su propuesta considera información relacionada con el funcionamiento del vehículo, como variables de temperatura, presión, vibración y emisiones, y evalúa técnicas de aprendizaje automático para apoyar la detección de condiciones anómalas. Entre las estrategias descritas se encuentran el uso de bosques aleatorios y técnicas de procesamiento o selección de características, así como la comparación de clasificadores.

Los autores evalúan el desempeño mediante métricas de clasificación y herramientas de análisis como matrices de confusión y curvas ROC. Sus resultados ilustran la utilidad de los modelos de aprendizaje automático para identificar patrones asociados con condiciones mecánicas relevantes. Sin embargo, el problema estudiado y la configuración de los datos no son idénticos a los de EngineFaultDB. En particular, los resultados obtenidos con otra flota, otras variables o una definición diferente de las clases no deben interpretarse como una medida directa del desempeño que podría alcanzarse en el conjunto de datos del presente proyecto.

En conjunto, estos estudios complementarios muestran que el diagnóstico basado en datos puede abordarse con distintos tipos de señales, modelos y estrategias de representación. Al mismo tiempo, evidencian la importancia de describir con claridad el conjunto de datos, la definición de las clases, las variables utilizadas y el protocolo de evaluación para interpretar correctamente los resultados.

“‘latex

III-C. Síntesis y brecha metodológica

En conjunto, los trabajos revisados evidencian avances en la clasificación de condiciones de funcionamiento y fallas en motores de combustión interna mediante modelos de aprendizaje automático. En particular, las investigaciones basadas en EngineFaultDB proporcionan referencias relevantes para el problema estudiado; sin embargo, las diferencias en las variables utilizadas, la configuración de los modelos y los procedimientos de evaluación dificultan la comparación directa de sus resultados. Asimismo, los estudios sobre reducción de dimensionalidad muestran que su efecto depende del método empleado y del clasificador considerado, por lo que su utilidad debe determinarse experimentalmente y no asumirse de antemano.

En este contexto, se identifica la oportunidad de realizar una evaluación comparativa de modelos de aprendizaje automático supervisado sobre las cuatro categorías de EngineFaultDB, utilizando un protocolo experimental común y métricas que permitan analizar tanto el desempeño global como los errores por clase. Adicionalmente, se estudiará el efecto de técnicas de reducción de dimensionalidad, como PCA y UMAP, sobre el desempeño de los modelos seleccionados. De esta manera, el proyecto busca aportar evidencia experimental reproducible sobre el comportamiento de diferentes estrategias de clasificación y representación de los datos, complementando los resultados existentes sin presuponer la superioridad de un modelo o técnica particular. “‘

REFERENCIAS

[1] M. Vergara, L. Ramos, N. D. Rivera-Campoverde, and F. Rivas-Echeverría, “EngineFaultDB: A novel dataset for automotive engine fault classification and baseline results,” *IEEE Access*, vol. 11, pp. 126155–126171, 2023, doi: 10.1109/ACCESS.2023.3331316.

[2] V. T. Nguyen, T. P. Nguyen, and L. V. Dat, “AI-based automotive engine diagnostics: Exploring the EngineFaultDB dataset for fault detection,” *HaUI Journal of Science and Technology*, vol. 61, no. 7E, Jul. 2025, doi: 10.57001/huih5804.2025.248.

[3] A. Srinivaas, N. R. Sakthivel, and B. B. Nair, “Machine learning approaches for fault detection in internal combustion engines: A review and experimental investigation,” *Informatics*, vol. 12, no. 1, Art. no. 25, Feb. 2025, doi: 10.3390/informatics12010025.

[4] P. R. Cajías-Arías, J. C. Ortiz-Reyes, C. S. Ulcuango-Moreno, and R. R. Alay-Romero, “Integración de inteligencia artificial para el diagnóstico predictivo de fallas mecánicas en vehículos de combustión interna: Enfoque integral,” *Polo del Conocimiento*, vol. 10, no. 5, pp. 2271–2289, May 2025, doi: 10.23857/pc.v10i5.9570.